УДК 004.8

М. С. Шутов[1]

[1]Московский физико-технический институт (национальный исследовательский университет)

Исследование применимости энтропийного кодирования для сжатия весов квантованных больших языковых моделей

Исследован потенциал дополнительного энтропийного сжатия весов пяти больших языковых моделей при использовании шести схем 4-битной квантизации. Оценена связь между энтропией квантованных кодов и точностью моделей. Показано, что потенциал дополнительного сжатия существенно зависит от схемы квантизации и способа масштабирования. Для современных схем с локальным масштабированием он составляет около 2,8–4,6%, а для схем с поканальным масштабированием и масштабированием по группам из 128 элементов – 10–13%. Использование схем с масштабированием на уровне тензора обеспечивает более высокую сжимаемость, но сопровождается критическим снижением точности моделей.

Ключевые слова: сжатие больших языковых моделей, квантизация, энтропийные методы сжатия

M. S. Shutov[1]

[1]Moscow Institute of Physics and Technology

On the applicability of entropy coding for weight compression of quantized large language models

The potential for additional entropy coding of the weights of five large language models was investigated using six 4-bit quantization schemes. The relationship between the entropy of quantized codes and model accuracy was evaluated. The results show that the potential for additional compression depends strongly on the quantization scheme and scaling method. For modern schemes with local scaling, it is approximately 2.8–4.6%, while channel-wise scaling and group-wise scaling with groups of 128 elements achieve 10–13%. Tensor-wise scaling provides higher compressibility but is accompanied by a critical reduction in model accuracy.

Key words: quantization, large language models, entropy coding

1. Введение

Большие языковые модели (БЯМ) широко используются в современных системах искусственного интеллекта, применяемых для генерации кода, анализа данных и поиска информации [1–3]. Однако развёртывание БЯМ сопряжено с высокими требованиями к аппаратным ресурсам, прежде всего к объёму и пропускной способности памяти, необходимой для хранения весов модели и обеспечения их передачи вычислительным блокам во время инференса. Сокращение объёма памяти, необходимого для хранения весов, позволяет снизить требования к аппаратному обеспечению и использовать менее дорогостоящие вычислительные платформы, уменьшая тем самым стоимость развёртывания БЯМ.

© Шутов М. С., 2027
© Федеральное государственное автономное образовательное учреждение высшего образования «Московский физико-технический институт (национальный исследовательский университет)», 2027

Одним из наиболее распространённых подходов к оптимизации объема памяти является квантизация весов БЯМ. Современные схемы 4-битной квантизации позволяют уменьшить объём представления весов примерно в 3,5–4 раза по сравнению с BF16, в зависимости от формата и накладных расходов на параметры масштабирования [4–6].

Альтернативный подход заключается в применении энтропийного кодирования, использующего статистическую избыточность последовательности значений. В отличие от квантизации, энтропийное кодирование обеспечивает сжатие без потерь и не изменяет значения кодируемых символов [7,8]. Ранее были продемонстрированы возможности применения таких методов к весам БЯМ, представленным в форматах с плавающей точкой. Однако дополнительный выигрыш от энтропийного кодирования зависит от статистических свойств представления весов и может быть ограничен для низкоразрядных форматов. Поэтому особый интерес представляет оценка возможностей энтропийного сжатия весов БЯМ после применения современных схем квантизации, ориентированных на сохранение точности модели. Несмотря на наличие исследований, посвящённых совместному применению квантизации и энтропийного кодирования [8,9], потенциал дополнительного сжатия весов, квантованных с использованием современных 4-битных схем, изучен недостаточно.

Цель настоящей работы – экспериментально оценить потенциал дополнительного сжатия квантованных весов больших языковых моделей с помощью энтропийного кодирования как для академических схем квантизации так и для схем, имеющих аппаратную поддержку на современных ускорителях вычислений.

Основные результаты работы:

- Для пяти больших языковых моделей и шести схем 4-битной квантизации оценен потенциал дополнительного сжатия весов с помощью энтропийного кодирования.
- Исследована связь между энтропией квантованных кодов и точностью моделей. Показано, что высокая сжимаемость не всегда обеспечивает сохранение точности.
- Установлено, что схема квантизации с масштабированием на уровне тензора обеспечивает высокий потенциал энтропийного сжатия, однако ее использование сопровождается критическим снижением точности моделей, что ограничивает практическую применимость этой схемы.

2. Теоретические основы

2.1. Квантизация весов больших языковых моделей

Квантизация весов нейронной сети представляет собой преобразование параметров из исходного числового формата в представление с меньшей разрядностью. Особый интерес представляют скалярные схемы квантизации, где каждому весу сопоставляется дискретный код из конечного множества допустимых значений.

Для равномерной скалярной квантизации преобразование вещественного веса W в квантованный код Q может быть представлено следующим образом:

$$Q(W) = clip(round(W/s) + z, Q_{min}, Q_{max}),$$

где s — параметр масштабирования, z — параметр смещения, а Q_{min} и Q_{max} — границы диапазона квантованных значений. Приближенное восстановление исходного веса $\hat{W}$ выполняется по формуле:

$$\hat{W} = s(Q - z).$$

В современных больших языковых моделях основная часть параметров сосредоточена в матрицах весов линейных слоев, поэтому на их сжатие ориентированы многие методы квантизации. Вместо одного параметра масштабирования для всей матрицы обычно используются локальные параметры масштабирования, позволяющие учитывать неоднородность распределения весов. Конкретные правила группировки и представления параметров зависят от рассматриваемой схемы квантизации.

2.2. Энтропийное кодирование

Квантованные веса модели представлены дискретными кодами, распределение которых определяет потенциал дополнительного сжатия. Его можно оценить с помощью энтропии Шеннона:

$$H = -\sum_i p_i \log_2 p_i,$$

где p_i — частота i-го кода. Для 4-битных кодов $H_{max} = 4$. Чем ниже H, тем выше потенциальная сжимаемость данных за счёт статистической избыточности.

Энтропийное кодирование представляет собой класс методов сжатия без потерь, в которых размер сжатого представления определяется статистическими характеристиками кодируемых элементов. Для независимого поэлементного кодирования энтропия задаёт нижнюю границу средней длины кодирования. К распространённым методам относятся кодирование Хаффмана, арифметическое кодирование и асимметричные системы счисления.

В научном сообществе активно исследуется применимость энтропийного кодирования для сжатия весов БЯМ. В частности, в работе [7] предложен метод DFloat11 для сжатия весов БЯМ в формате BF16 без потери информации. DFloat11 использует меньшую энтропию экспонент по сравнению с их исходным восьмибитным представлением; для их сжатия применяется кодирование Хаффмана. Авторы сообщают о сокращении объёма хранения весов приблизительно на 30%.

В работе [8] предложен метод сжатия весов BF16 на основе блочного rANS (range Asymmetric Numeral Systems). Метод предполагает независимое кодирование блоков матриц весов БЯМ, причем разбиение на блоки согласовано с организацией матричных умножений на современных ускорителях вычислений, что позволяет декодировать необходимые веса непосредственно во время выполнения матричных умножений, не требуя предварительной распаковки всей матрицы. Авторы сообщают о сжатии в 1,4-1,5 раза без потерь и ускорении генерации ответов до 20% в отдельных сценариях.

Несмотря на возможность сжатия без потерь, эффективность таких методов ограничена статистической избыточностью исходных весов и накладными расходами на декодирование. Квантизация обеспечивает более существенное сокращение объёма, но может снижать точность модели. Большой интерес представляет энтропийное сжатие квантованных весов, позволяющее дополнительно уменьшить их размер.

2.3. Совместное применение квантизации и энтропийного кодирования

В существующих работах рассматриваются различные сочетания квантизации и энтропийного кодирования весов БЯМ [8, 9]. Однако результаты таких исследований не всегда позволяют оценить потенциал дополнительного сжатия для современных низкоразрядных форматов.

В работе [8] проводится, в частности, анализ энтропии квантованных весов. Авторы отмечают, что сжатие моделей, квантованных с помощью AWQ [10], ограничено 10-30%, а квантизация весов в INT4 с масштабированием на уровне всего тензора позволяет получать последовательности кодов с крайне низкой энтропией и потенциалом дополнительного сжатия порядка 10 раз.

В работе [9] представлен метод EntroLLM, объединяющий квантизацию весов и кодирование Хаффмана. Авторы применяют квантизацию весов БЯМ в 4-битный формат с масштабированием на уровне тензора, что обеспечивает концентрацию значений в небольшом числе кодов и, следовательно, низкую энтропию. Для БЯМ Phi-3-mini-4k сообщается о снижении средней длины представления весов до 1.39 бита на вес без существенного изменения в точности работы модели.

Однако в работах [8,9] не исследован ряд современных схем квантизации, позволяющих сохранять приемлемую точность моделей. Рассмотренная в [9] квантизация с масштабированием на уровне тензора ограничивает применимость результатов к современным БЯМ:

такая квантизация может сопровождаться существенным снижением точности модели [10].

В настоящей работе исследуется потенциал сжатия весов БЯМ энтропийными методами после применения современных схем квантизации, включая MXFP4, NVFP4, HiF4.

3. Настройки экспериментов

В работе исследуется возможность дополнительного сжатия весов БЯМ после применения низкоразрядной квантизации. Основной акцент сделан на схемах квантизации с четырёхбитными кодами в силу их практического интереса. В данном разделе описаны исследуемые схемы квантизации, методы энтропийного кодирования и БЯМ.

В качестве исследуемых схем квантизации были выбраны шесть схем 4-битной квантизации: три схемы, получившие аппаратную поддержку на современных ускорителях: MXFP4, NVFP4 и HiF4; остальные три схемы используют INT4 коды с различной гранулярностью параметров масштабирования. Основные характеристики исследуемых схем представлены в Таблице 1.

Т а б л и ц а 1

Исследуемые схемы квантизации

Схема квантизации	Формат кодов	Масштабирование (гранулярность; формат масштаба)	Длина кодирования, бит/вес
MXFP4 [4]	FP4	Группы по 32; тип данных E8M0	4.25
NVFP4 [5]	FP4	Группы по 16; тип данных FP8 (E4M3) и глобальный масштаб FP32	4.50
HiF4 [6]	Симметрич. INT4	Группы по 64 элемента, три уровня масштабирования степенями двойки	4.50
INT4-TENSOR	INT4	Параметр на тензор, FP16	∼4.00
INT4-CHANNEL	INT4	Параметр на канал, FP16	∼4.00
INT4-gs128	INT4	Группы по 128 элементов, FP16	4.125

Схемы INT4-TENSOR и INT4-CHANNEL включены в исследование в качестве контрольных вариантов. В современных схемах квантизации БЯМ широко применяется групповое масштабирование, однако в работах по энтропийному сжатию не всегда достаточно подробно описана методология квантизации для независимого воспроизведения результатов. В частности, в работе [8] точная спецификация INT4-схемы не приведена, тогда как в [9] прямо рассматривается схема квантизации с одним параметром масштабирования на тензор как средство повышения сжимаемости весов без снижения точности модели, но методология, обеспечивающая низкую деградацию точности, в работе не раскрыта.

В настоящей работе во всех экспериментах рассматривается квантизация только весов линейных слоев в блоках трансформера. Для квантизации весов с MXFP4, NVFP4 и HiF4 используются алгоритмы из [4–6]. В INT4-схемах масштабирующие параметры подбираются поиском по сетке, минимизирующим ошибку реконструкции весов.

В работе исследуются два подхода к энтропийному сжатию квантованных весов БЯМ, предложенные в недавних исследованиях: кодирование Хаффмана в [9] и кодирование на основе блочного rANS в работе [8]. Для кодирования блочным rANS использовался размер блока 128×32 элемента.

В исследовании рассматриваются пять больших языковых моделей из трёх семейств: LLaMA-3 [1], Qwen-3 [2] и Gemma-4 [3]. Выбранный набор включает модели различного масштаба — от 8 до 70 млрд параметров, а также модель с архитектурой смеси экспертов. Для анализа влияния квантизации на энтропию используется единая процедура преобразования весов без дополнительного обучения моделей на калибровочном наборе данных. Такой выбор позволяет исследовать статистические характеристики самих схем квантизации, не смешивая их с влиянием калибровочных данных или последующей оптимизации параметров. Отдельно рассматриваются публично доступные квантованные модели, для

которых квантизация с калибровкой или обучение с учётом квантизации уже выполнены авторами соответствующих моделей (П.4.2).

4. Численные эксперименты

4.1. Энтропия как показатель сжимаемости квантованной модели

Энтропия квантованных весов позволяет оценить теоретический потенциал их сжатия, однако практический результат зависит от используемого метода кодирования. Поэтому на первом этапе исследуется, насколько близка средняя длина кодирования после энтропийного кодирования к соответствующей оценке энтропии. В рамках этого эксперимента исследуется средняя энтропия и потенциал реального сжатия квантованных кодов линейных слоев модели Qwen3-8B. Для получения средней по всем тензорам модели энтропии вычислялась энтропия квантованных кодов каждого тензора, после чего результаты усреднялись с весами, пропорциональными числу параметров соответствующего слоя. Результаты измерений представлены в таблице 2.

Таблица 2

Сравнение длины кодирования с энтропийной оценкой (Qwen3-8B)

Схема квантизации	Средняя энтропия по тензору, бит	Средняя длина кодирования, Хаффман по тензору, бит	Средняя энтропия по блокам 128×32, бит	Средняя длина кодирования, rANS по блокам 128×32, бит
NVFP4	3,884	3,910	3,880	3,889
MXFP4	3,860	3,897	3,853	3,862
HiF4	3,810	3,838	3,806	3,815
INT4-TENSOR	0,477	1,150	0,475	0,484
INT4-CHANNEL	3,473	3,493	3,468	3,477
INT4-gs128	3,542	3,559	3,536	3,545

Для большинства рассмотренных схем средняя длина кодирования близка к энтропийной оценке. Для INT4-TENSOR кодирование Хаффмана даёт заметно большую длину кода, чем следует из энтропии тензора (1,15 против 0,48 бит/код). Это связано с тем, что при обычном поэлементном кодировании Хаффмана длина кодового слова не может быть меньше одного бита. Для остальных схем средняя длина кодирования превышает среднюю по тензору энтропию не более чем на 0,98% при кодировании по Хаффману и не более чем на 0,12% при блочном rANS (не более чем на 0,26% относительно поблочной энтропии).

Таким образом, энтропия квантованных кодов позволяет оценить потенциал дополнительного сжатия для большинства рассмотренных схем квантизации. Это наблюдение подтверждает результаты [8], расширяя их на современные схемы скалярной квантизации. Во всех последующих экспериментах для оценки дополнительного сжатия используется именно средняя по всем тензорам модели энтропия (далее просто энтропия кодов модели).

4.2. Энтропия публичных квантованных моделей

Для оценки потенциала энтропийного сжатия реальных моделей исследуется энтропия весов публично доступных квантованных моделей семейств Llama, Qwen и Gemma. В отличие от INT4-TENSOR, для которой не удалось найти публично доступные наборы весов, в выборку включены модели с широко используемыми на практике схемами квантизации, в том числе INT4-gs128 и NVFP4, а также GGUF Q4_0 – схема скалярной INT4 квантизации с размером группы в 32 веса и масштабами в формате FP16. Для оценки потенциала дополнительного сжатия квантованных моделей измерялась энтропия кодов модели. Результаты измерений представлены в таблице 3.

Таблица 3

Энтропия публичных квантованных моделей

Модель	Схема квантизации	Энтропия	Ссылка на веса квантованной модели
Llama-3-8B	INT4-gs128	3,612	https://huggingface.co/ISTA-DASLab/Llama-3-8B-Instruct-GPTQ-4bit
Llama-3-70B	INT4-gs128	3,579	https://huggingface.co/ISTA-DASLab/Llama-3.3-70B-Instruct-HIGGS-4bit
Qwen3-8B	NVFP4	3,963	https://huggingface.co/ISTA-DASLab/Qwen3-8B-FPQuant-QAT-NVFP4-1400steps
Qwen3-30B-A3B	INT4-gs128	3,450	https://huggingface.co/Qwen/Qwen3-30B-A3B-GPTQ-Int4
gemma-4-12b	GGUF Q4_0	3,790	https://huggingface.co/google/gemma-4-12B-it-qat-q4_0-gguf

Энтропия квантованных кодов исследованных моделей составляет от 3,450 до 3,963 бит. Относительно исходного 4-битного представления это соответствует потенциальному сокращению длины кодирования примерно на 0,9–13,8% в зависимости от модели и схемы квантизации. Это указывает на ограниченный потенциал дополнительного сжатия кодов весов посредством энтропийного кодирования рассмотренных моделей, квантованных с использованием современных схем.

4.3. Исследование сжимаемости различных элементов моделей

Средняя энтропия модели может скрывать различия между отдельными слоями: статистические свойства весов потенциально зависят от глубины слоя и его функционального назначения. Для проверки этой гипотезы анализируется энтропия по блокам трансформера и типам линейных слоёв в трёх общедоступных квантованных моделей: Llama3-8B и Qwen3-30B-A3B с INT4-gs128, а также Qwen3-8B с NVFP4. Для каждой модели сопоставляются результаты квантизации с калибровкой/обучением (GPTQ или QAT) и без калибровки (рисунок 1).

Во всех трёх моделях обнаружена неоднородность энтропии по глубине трансформера и типам линейных слоёв. Вместе с тем в большинстве блоков отклонение от среднего значения не превышает 1%, наибольшие отклонения (до 5%) наблюдаются в первых блоках (рис. 1, A1, B1, C1). Отличие средней энтропии разных типов слоев ограничено 2% (рис. 1, A2, B2, C2). Блоки с заметно более низкой энтропией составляют малую долю параметров, поэтому выборочное энтропийное кодирование отдельных блоков или типов слоев не даст значительного выигрыша в рассмотренных конфигурациях.

Влияние калибровки или обучения с учетом квантизации зависит от модели: средняя энтропия выросла на примерно 0,4% (Llama-3-8B, GPTQ) и на 2,0% (Qwen3-8B, QAT, NVFP4), снизилась на 4% (Qwen3-30B-A3B, GPTQ). Полученные результаты не позволяют установить устойчивую зависимость между применением калибровки или QAT и изменением энтропии кодов.

4.4. Связь энтропии кодов с точностью квантованной модели

Квантизация модели может сопровождаться существенным снижением качества моделирования языка и точности ответов на вопросы. Низкая энтропия кодов указывает на возможность дополнительного сжатия, но может быть и следствием сильного искажения весов: при вырожденном распределении кодов точность модели может значительно снизиться. Поэтому необходимо установить связь между сжимаемостью кодов и сохранением точности модели. Для оценки изменения точности моделей до и после квантизации были

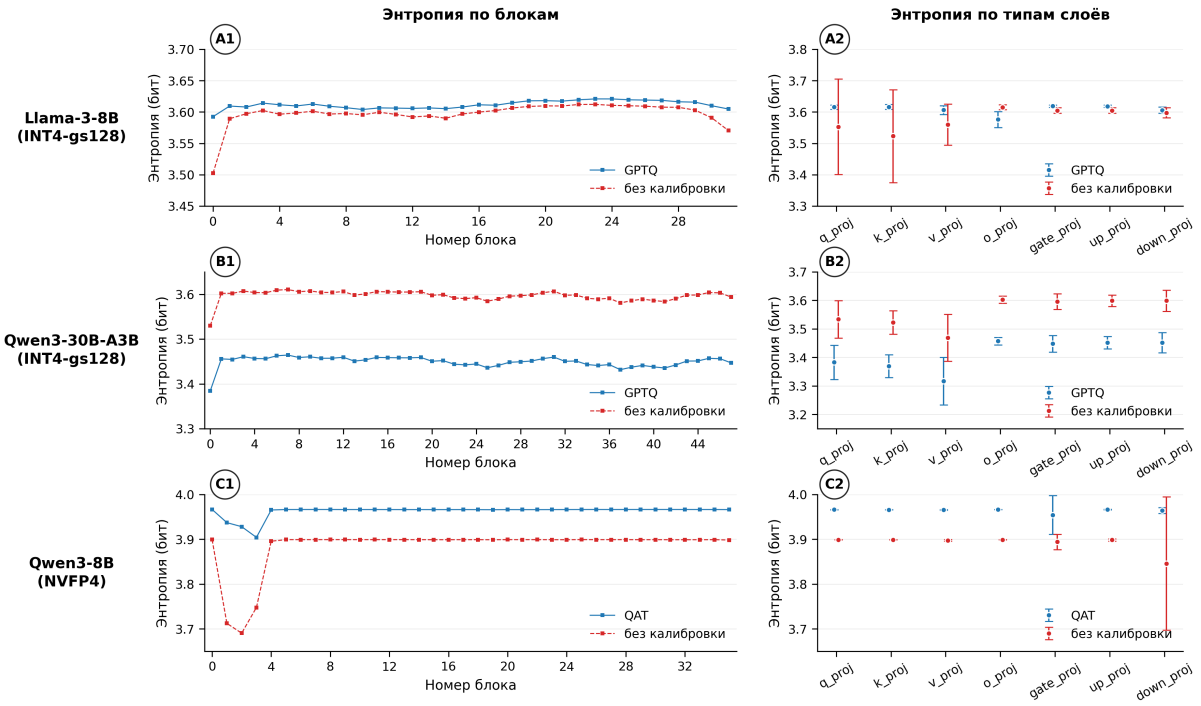


Рис. 1. Исследование зависимости энтропии кодов квантованной модели от глубины и типа слоя. Сравнение энтропии квантованных моделей с и без калибровки/обучения.

использованы 4 теста: ARC-Challenge [11] и HellaSwag [12] в режиме без примеров в контексте (zero-shot), GSM8K [14] и MMLU [13] в режиме с пятью примерами в контексте (5-shot). Для запуска тестов использовалась библиотека lm-evaluation-harness. В качестве наглядного количественного показателя точности модели использовалось среднее арифметическое точности ответов на четырех тестах.

Для оценки изменения точности моделей использовалось отношение точности после квантизации ACC_q к точности модели до квантизации ACC_{fp}: $k = ACC_q/ACC_{fp}$. Для оценки потенциала сжатия квантованных кодов вычислялась средняя нормированная энтропия $H_{norm} = H/4$. Для рассматриваемых пяти моделей и шести схем квантизации были вычислены k и H_{norm}; результаты эксперимента представлены на рисунке 2. Полная таблица рассчитанных метрик представлена по ссылке `https://github.com/MiShutov/entropy_coding_for_quantized_llm`

На рисунке 2 для визуального сопоставления результатов выделены четыре области, соответствующие сочетаниям нормированной энтропии и точности моделей. Область A представляет наибольший интерес, поскольку указывает на потенциал дополнительного сжатия без существенной потери качества. Область B характеризуется ограниченными возможностями дополнительного сжатия при сохранении точности модели. В области C модель демонстрирует низкую точность при ограниченном потенциале сжатия. Наконец, область D соответствует потенциально высокой степени сжатия, сопровождающейся существенной деградацией качества модели.

Распределение экспериментальных точек показывает, что экстремально низкая энтропия сочетается с резким снижением точности, а минимальное снижение точности, как правило, сопровождается низким потенциалом дополнительного сжатия. Все модели, квантованные с использованием MXFP4, NVFP4, HiF4 находятся в области (B) или в непосредственной близости к ней, потенциал их дополнительного сжатия менее 5%. В исследованных конфигурациях INT4-TENSOR высокий потенциал сжатия сопровождался существенным снижением точности, что ограничивает практическую применимость этой схемы при выбранной процедуре квантизации. Модели, квантованные с использованием схем INT4-CHANNEL и INT4-gs128, находятся в диапазоне нормированной энтропии 0,87-0,90, что

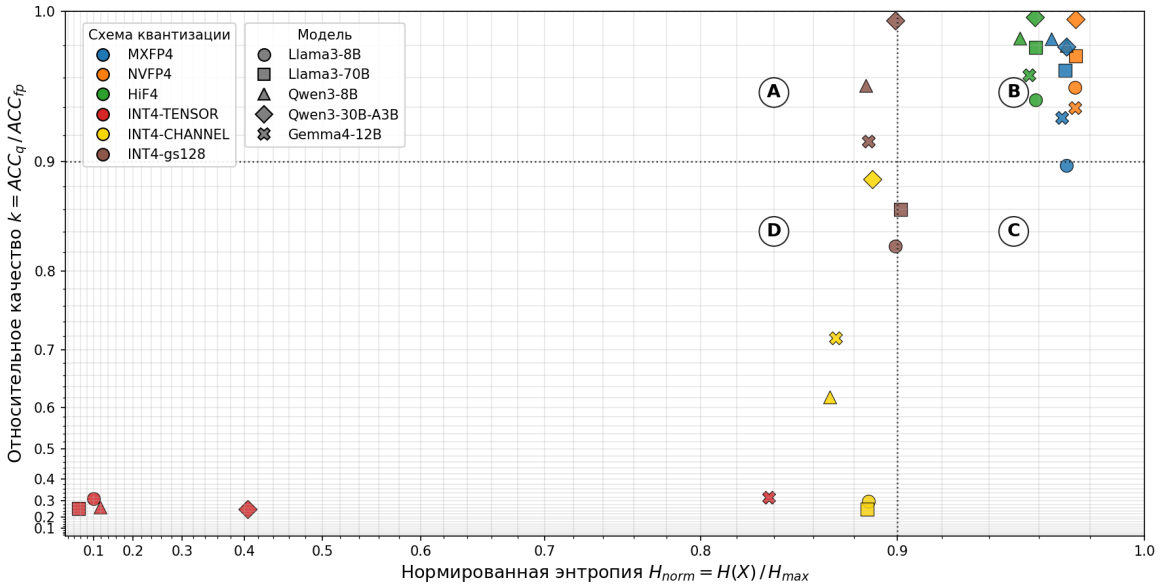


Рис. 2. Относительная точность k квантованных моделей в зависимости от нормированной энтропии кодов H_{norm}. Пунктир: $H_{norm} = 0,9$ и $k = 0,9$ (условные границы областей A–D).

позволяет оценить потенциал их сжатия в 10-13%.

5. Обсуждение результатов и ограничения работы

Оценка потенциала сжатия кодов порядка 10 раз из [8] и эффективные 1,39 бит/вес [9] сопоставимы по порядку величины с результатами для схемы INT4-TENSOR, однако при такой схеме квантизации точность модели утрачивается (рис. 2). Готовых моделей с рассматриваемыми архитектурами (Qwen 3, LLaMA 3, Gemma 4), квантованных с использованием INT4-TENSOR (или аналогичных схем), в открытом доступе найти не удалось. Эти результаты позволяют предположить, что рассмотренная конфигурация INT4-TENSOR пока не обеспечивает приемлемого компромисса между степенью сжатия и сохранением точности для исследованных моделей.

Для схем с квантизацией в INT4 скаляры с групповым масштабированием потенциал сжатия кодов порядка 10% согласуется с оценкой 1,1–1,3 из [8]. Потенциальное сокращение объёма представления весов примерно на 10% может быть полезно при хранении и передаче моделей, особенно в условиях ограниченной пропускной способности каналов передачи данных или дискового пространства. Однако ускорение модели при таком сжатии остается под вопросом и требует дополнительных исследований.

Дополнительное сжатие кодов для схем MXFP4, NVFP4 и HiF4 составляет лишь 2,8-4,6%, что ограничивает практическую целесообразность их энтропийного кодирования с учётом накладных расходов на декодирование.

Значительного выигрыша от выборочного энтропийного сжатия отдельных слоёв рассмотренных моделей (П.4.3) не обнаружено. Выборочное энтропийное кодирование отдельных блоков может оказаться более эффективным при смешанном использовании схем квантизации, если такие схемы приводят к существенным различиям в распределении кодов между слоями.

Результаты экспериментального исследования относятся к кодам весов. Для оценки выигрыша по объёму представления квантуемых слоев необходимо учитывать накладные расходы на параметры масштабирования. Например, для Llama3-8B из П.**??** сжатие кодов можно оценить в 9,7% (4,0 бит/код $\rightarrow$ 3,61 бит/код), но сжатие представления весов оценивается только в 9,1% (4,125 бит/вес $\rightarrow$ 3,737 бит/вес). Для оценки уменьшения затрат памяти на модель в целом нужно учитывать в том числе расход памяти на модули, которые

не квантуются.

Ограничения работы. К ограничениям исследования относятся использование энтропии нулевого порядка, не учитывающей зависимости между соседними кодами, отсутствие исследования сжатия параметров масштабирования (они составляют около 6% для MXFP4 и 11% для NVFP4) и ограниченный набор исследованных схем квантизации. Кроме того, полученные оценки не затрагивают вычислительных затрат на декодирование. Поэтому оценка практического выигрыша требует дополнительных экспериментов с учётом служебных расходов и особенностей исполнения моделей на целевом оборудовании.

6. Заключение

В работе экспериментально исследована применимость энтропийного кодирования для дополнительного сжатия квантованных весов больших языковых моделей.

Установлено, что возможности энтропийного сжатия существенно зависят от схемы квантизации. Для MXFP4, NVFP4 и HiF4 энтропия кодов близка к максимально возможной для 4-битного представления, поэтому дополнительное сжатие ограничено приблизительно 2,8–4,6%. Для схем INT4-CHANNEL и INT4-gs128 потенциальное сокращение объёма кодов составляет порядка 10–13%. Вместе с тем низкая энтропия INT4-TENSOR, обеспечивающая значительно более высокую степень сжатия, сопровождается существенным снижением точности модели. Таким образом, высокая сжимаемость сама по себе не является достаточным критерием практической применимости схемы квантизации.

Перспективы дальнейших исследований связаны с экспериментальной оценкой практической эффективности энтропийного сжатия при выполнении БЯМ на целевых аппаратных платформах. В частности, необходимо исследовать влияние декодирования квантованных кодов на задержку генерации и пропускную способность модели, а также оценить итоговое сокращение объёма хранимых весов с учётом накладных расходов на параметры масштабирования и служебные данные.

Список литературы

1. *Grattafiori A., et al.* The Llama 3 herd of models // arXiv preprint arXiv:2407.21783. 2024.
2. *Yang A., et al.* Qwen3 technical report // arXiv preprint arXiv:2505.09388. 2025.
3. *Team G., et al.* Gemma 4 technical report // arXiv preprint arXiv:2607.02770. 2026.
4. *Rouhani B.D., et al.* Microscaling data formats for deep learning // arXiv preprint arXiv:2310.10537. 2023.
5. *Abecassis F., et al.* Pretraining large language models with NVFP4 // arXiv preprint arXiv:2509.25149. 2025.
6. *Luo Y., et al.* HiFloat4 format for language model inference // arXiv preprint arXiv:2602.11287. 2026.
7. *Zhang T., et al.* 70% size, 100% accuracy: Lossless LLM compression for efficient GPU inference via dynamic-length float (DFloat11) // Advances in Neural Information Processing Systems. 2025. V. 38. P. 98966–98994.
8. *Tan H., et al.* Approaching Shannon Bound with Lossless LLM Weight Compression // Proceedings of the 53rd Annual International Symposium on Computer Architecture (ISCA). Raleigh, NC, USA, 2026. P. 116–130. DOI: 10.1109/ISCA66397.2026.00024.
9. *Sanyal A., et al.* EntroLLM: Entropy Encoded Weight Compression for Efficient Large Language Model Inference on Edge Devices // Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2026. P. 19742–19746.

10. *Lin J., et al.* AWQ: Activation-aware Weight Quantization for LLM Compression and Acceleration // Proceedings of Machine Learning and Systems (MLSys). 2024.

11. *Clark P., et al.* Think you have solved question answering? Try ARC, the AI2 reasoning challenge // arXiv preprint arXiv:1803.05457. 2018.

12. *Zellers R., et al.* HellaSwag: Can a machine really finish your sentence? // Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL 2019). 2019. P. 4791–4800. DOI: 10.18653/v1/p19-1472.

13. *Hendrycks D., et al.* Measuring Massive Multitask Language Understanding // Proceedings of the 9th International Conference on Learning Representations (ICLR 2021). Virtual Event, Austria, 2021.

14. *Cobbe K., et al.* Training verifiers to solve math word problems // arXiv preprint arXiv:2110.14168. 2021.

References

1. *Grattafiori A., et al.* The Llama 3 herd of models // arXiv preprint arXiv:2407.21783. 2024.

2. *Yang A., et al.* Qwen3 technical report // arXiv preprint arXiv:2505.09388. 2025.

3. *Team G., et al.* Gemma 4 technical report // arXiv preprint arXiv:2607.02770. 2026.

4. *Rouhani B.D., et al.* Microscaling data formats for deep learning // arXiv preprint arXiv:2310.10537. 2023.

5. *Abecassis F., et al.* Pretraining large language models with NVFP4 // arXiv preprint arXiv:2509.25149. 2025.

6. *Luo Y., et al.* HiFloat4 format for language model inference // arXiv preprint arXiv:2602.11287. 2026.

7. *Zhang T., et al.* 70% size, 100% accuracy: Lossless LLM compression for efficient GPU inference via dynamic-length float (DFloat11) // Advances in Neural Information Processing Systems. 2025. V. 38. P. 98966–98994.

8. *Tan H., et al.* Approaching Shannon Bound with Lossless LLM Weight Compression // Proceedings of the 53rd Annual International Symposium on Computer Architecture (ISCA). Raleigh, NC, USA, 2026. P. 116–130. DOI: 10.1109/ISCA66397.2026.00024.

9. *Sanyal A., et al.* EntroLLM: Entropy Encoded Weight Compression for Efficient Large Language Model Inference on Edge Devices // Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2026. P. 19742–19746.

10. *Lin J., et al.* AWQ: Activation-aware Weight Quantization for LLM Compression and Acceleration // Proceedings of Machine Learning and Systems (MLSys). 2024.

11. *Clark P., et al.* Think you have solved question answering? Try ARC, the AI2 reasoning challenge // arXiv preprint arXiv:1803.05457. 2018.

12. *Zellers R., et al.* HellaSwag: Can a machine really finish your sentence? // Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL 2019). 2019. P. 4791–4800. DOI: 10.18653/v1/p19-1472.

13. *Hendrycks D., et al.* Measuring Massive Multitask Language Understanding // Proceedings of the 9th International Conference on Learning Representations (ICLR 2021). Virtual Event, Austria, 2021.

14. *Cobbe K., et al.* Training verifiers to solve math word problems // arXiv preprint arXiv:2110.14168. 2021.

Поступила в редакцию дд.мм.гггг

Сведения об авторах статей
(на момент подачи статьи)

Исследование применимости энтропийного кодирования для сжатия весов квантованных больших языковых моделей

Шутов Михаил Сергеевич (Федеральное государственное автономное образовательное учреждение высшего образования

«Московский физико-технический институт (национальный исследовательский университет)»)
mihailshutov105@gmail.com

Ссылки на опубликованные статьи
(в соответствии с ГОСТ Р 7.0.5-2008)

Шутов М.С. Исследование применимости энтропийного кодирования для сжатия весов квантованных больших языковых моделей // Труды МФТИ. 2027. Т. 19, № 2. С. 1–11.

Shutov M.S. On the applicability of entropy coding for weight compression of quantized large language models // Proceedings of MIPT. 2027. V. 19, N 2. P. 1–11.